Arquitectura Relacional y Análisis Estadístico de Metadatos de ECG en HEEDB

Descripción de Archivos, Modelo Entidad-Relación y Distribución de Arritmias

Documentación Técnica de Datos y Análisis Exploratorio

Octubre de 2026

Resumen

Este documento presenta la arquitectura relacional y el análisis exploratorio de metadatos de la base de datos *Harvard-Emory ECG Database* (HEEDB), un repositorio clínico de escala masiva que reúne más de 11.6 millones de electrocardiogramas (ECG) de 12 derivaciones provenientes del *Massachusetts General Hospital* (MGH) y de *Emory Healthcare*. El trabajo se estructura en tres componentes clave:

- **Arquitectura Relacional y Catálogo de Datos**: Formalización de las tablas principales, claves de enlace e integridad referencial en un modelo Entidad-Relación modular para la trazabilidad completa del paciente.
- **Evidencia Estadística y Enfoque Multietiqueta**: Análisis de prevalencias sobre 9.6 millones de estudios con supervisión médica, demostrando que el 98.6 % presenta diagnósticos compuestos y justificando el modelado multietiqueta.
- **Ingeniería de Señales, IA y Viabilidad Computacional**: Solución a la disparidad de muestreo mediante filtrado antialiasing a 250 Hz, aseguramiento de calidad asistido por IA y una estrategia escalonada (piloto de 100,000 trazos y carga por demanda).

Índice

1. Descripción del Conjunto de Datos y Organización de Archivos 2
2. Catálogo y Función de Cada Archivo 2
3. Modelo Entidad-Relación de los Datos 3
4. Resumen Estadístico: Arritmias Identificadas por Hospital 4
5. Consideraciones de Normalización, Viabilidad y Procesamiento 8
6. Diccionario de Conceptos Clave (Glosario Técnico y Clínico) 10
7. Referencias Bibliográficas 11

1. Descripción del Conjunto de Datos y Organización de Archivos

La base de datos HEEDB reúne trazados de electrocardiografía recopilados durante la atención médica cotidiana en dos centros hospitalarios universitarios de Estados Unidos. Los registros se encuentran alojados en Amazon Web Services (AWS S3) dentro de la plataforma abierta BDSP (*Brain Data Science Platform*):

- **MGH (I0001)**: 10,608,415 trazados de ECG pertenecientes a 1,818,247 pacientes, adquiridos entre los años 1980 y 2022.
- **Emory (I0006)**: 998,844 trazados de ECG pertenecientes a 349,548 pacientes, adquiridos entre los años 2010 y 2019.

En cada institución, los datos se estructuran en tres carpetas principales con metadatos tabulares (`metadata/`, `12SL_diagnoses/` e `ICD_codes/`) y un repositorio con las señales fisiológicas binarias en formato estándar WFDB.

2. Catálogo y Función de Cada Archivo

A continuación se detalla la función técnica, las claves de enlace y el contenido de cada archivo en el repositorio:

1. `metadata.csv` (Datos Demográficos y Contexto del Estudio): Centraliza los datos demográficos del paciente y las circunstancias de cada registro médico. Su clave primaria (`PK`) es `FileName` (la ruta única del trazo en S3) y su clave foránea (`FK`) es `BDSPPatientID`, estableciendo una relación de uno a muchos ($1 : N$). Incluye variables de sexo, raza (`PatientRace`), fecha y hora de adquisición (`ECGAcquisitionTime`) y la edad del sujeto (`AgeAtAcquisition`, almacenada en días; para expresarla en años se divide entre 365.25).

2. `diagnoses_acquisition.csv` (Diagnósticos en Adquisición y Criterio Médico): Almacena los diagnósticos asignados en el momento exacto del examen ($1 : 1$ con `metadata.csv`). Contiene los códigos producidos por el software de adquisición (`codes_software`), las etiquetas revisadas y confirmadas por el médico especialista o cardiólogo (`codes_physician`, que constituyen el patrón de referencia clínico definitivo) y el índice de concordancia `jaccard_index`.

3. `diagnoses_v24.csv` (Diagnósticos Reprocesados Homogéneos): Proporciona los diagnósticos resultantes de reprocesar todos los trazados bajo la misma versión 24 del algoritmo GE Marquette 12SL ($1 : 0..1$ con `metadata.csv`). Esta tabla permite comparar exámenes tomados en distintas épocas bajo un software unificado, neutralizando variaciones por versiones históricas de firmware (cobertura: 98.7 % en MGH y 97.5 % en Emory).

4. `diagnoses_dictionary.csv` (Diccionario Ontológico Maestro): Funciona como el catálogo maestro de traducción para 505 conceptos médicos estandarizados. Su clave primaria (`PK`) es el código numérico entero (`codes`). Proporciona la sigla clínica (`acronym`, como `AFIB`, `NSR` o `PVC`) y la descripción textual completa (`diagnoses`) para interpretar con precisión los números de las tablas.

5. `icd9_codes.csv` e `icd10_codes.csv` (Diagnósticos Hospitalarios): Registran los diagnósticos de la historia clínica hospitalaria codificados bajo los estándares CIE-9 y CIE-10, asociados mediante `BDSPPatientID` y la fecha `RECORDED_DT`. Describen la condición general del paciente en el hospital y no dependen de la señal de un ECG individual.

6. Archivos Físicos WFDB en S3 (Señales de 12 Derivaciones): Cada estudio físico está integrado por dos archivos complementarios: un encabezado de texto plano (`.hea`) con la frecuencia de muestreo ($f_s = 250$ o 500 Hz) y las constantes de calibración, y una matriz binaria con los 10 segundos continuos de señal en las 12 derivaciones estándar (`.mat` en MGH y `.dat` en Emory).

3. Modelo Entidad-Relación de los Datos

El diseño relacional de HEEDB está pensado para desacoplar los datos permanentes del paciente de los múltiples exámenes que acumula a lo largo del tiempo. El siguiente diagrama ilustra la arquitectura de datos agrupada por dominios funcionales:

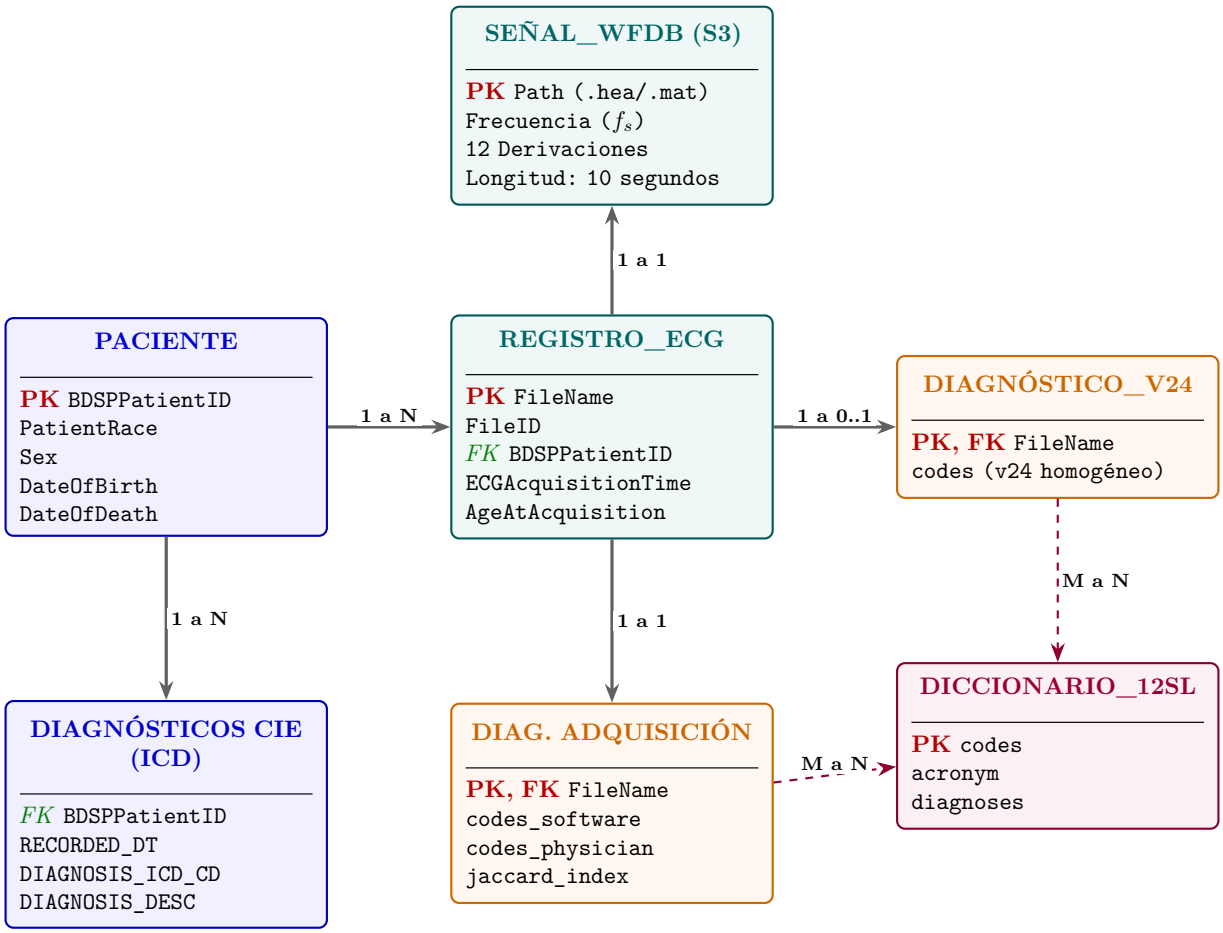


Figura 1: Diagrama Entidad-Relación de HEEDB. Muestra la jerarquía modular desde el paciente y sus registros de señal física hasta las capas de anotación médica, algorítmica y el catálogo de traducción ontológica.

Como refleja el diagrama, un mismo paciente acumula diversos trazados a lo largo de los años. Cada examen enlaza su señal física con la metadata demográfica y con dos fuentes diagnósticas independientes: las etiquetas del cardiólogo (`codes_physician`) y la versión homogénea algorítmica (`diagnoses_v24.csv`), ambas interpretables mediante el catálogo ontológico unificado.

4. Resumen Estadístico: Arritmias Identificadas por Hospital

4.1 Origen de los Datos y Criterio de Selección Médica

Para asegurar que los hallazgos reflejen con fidelidad el criterio clínico y no predicciones de software preliminar, el análisis estadístico toma como fundamento exclusivo las anotaciones médicas confirmadas:

- **Fuente primaria**: Se analizó el campo `codes_physician` de `diagnoses_acquisition.csv`, que almacena el diagnóstico validado por cardiólogos o médicos especialistas durante la atención.
- **Universo de estudio**: Se consideraron únicamente los estudios con supervisión médica documentada. Como detalla el Cuadro 1, esto abarca 998,168 exámenes en Emory (99.93 %) y 8,608,018 en MGH (81.14 %), consolidando un conjunto validado de **9,606,186 trazados**. Los estudios sin sobrelectura humana se excluyeron del cálculo para proteger la pureza del estándar de referencia.
- **Decodificación ontológica**: Cada código se tradujo a su nombre clínico oficial mediante el catálogo maestro `diagnoses_dictionary.csv`.

Centro Hospitalario	Total Registros	Con Médico	Sin Médico	% Cobertura
Emory (I0006)	998,844	998,168	676	**99.93 %**
MGH (I0001)	10,608,415	8,608,018	2,000,397	**81.14 %**
Total HEEDB	**11,607,259**	**9,606,186**	**2,001,073**	**82.76 %**

Cuadro 1: Cobertura de validación experta por cardiólogo/médico (`codes_physician`).

Concordancia con la publicación en *Nature Scientific Data* (2026): Al contrastar estos conteos locales con el artículo formal de HEEDB en *Scientific Data* (Koscova et al. [1]), se comprueba una concordancia exacta:

- **Emory University Hospital (EUH)**: Coincidencia del 100.000 % (998,844 trazados y 349,548 pacientes únicos en la base local, idénticos a los reportados en la publicación formal).
- **Massachusetts General Hospital (MGH)**: Coincidencia del 99.99998 % (10,608,415 registros frente a 10,608,417 reportados, y exactamente los mismos 1,818,247 pacientes únicos; la diferencia de 2 archivos responde a cabeceras ilegibles en descarga).

4.2 Prevalencia de las 12 Condiciones Cardíacas Seleccionadas

Para este análisis se seleccionaron 12 condiciones frecuentes y ampliamente estudiadas en la literatura médica [2, 1]. Para facilitar su comprensión e interpretación clínica, se agruparon en tres categorías funcionales:

1. **Ritmo de base y frecuencia**: Identifican el marcapasos y la velocidad cardíaca (ritmo sinusal normal, bradicardia < 60 lpm, taquicardia > 100 lpm, fibrilación auricular, flúter auricular y taquicardia auricular).
2. **Trastornos de conducción (bloqueos)**: Describen demoras o bloqueos en la propagación del impulso eléctrico (bloqueos de rama derecha o izquierda, y bloqueos auriculoventriculares de primer y tercer grado).
3. **Latidos prematuros (extrasístoles)**: Describen latidos anticipados que interrumpen el ritmo regular, originados en los ventrículos (PVC) o en las aurículas (PAC).

Cód.	Acr.	Diagnóstico Clínico	Emory ($N = 998$k)		MGH ($N = 8.6$M)	
			Casos	%	Casos	%
Grupo 1: Ritmo de Base y Frecuencia Cardíaca						
22	NSR	Ritmo Sinusal Normal	481,323	48.22 %	4,432,168	51.49 %
21	SBRAD	Bradicardia Sinusal (< 60 lpm)	135,277	13.55 %	975,406	11.33 %
23	STACH	Taquicardia Sinusal (> 100 lpm)	76,072	7.62 %	782,974	9.10 %
161	AFIB	Fibrilación Auricular	78,015	7.82 %	792,342	9.20 %
162	FLUT	Flúter Auricular	17,432	1.75 %	130,930	1.52 %
164	ATAC	Taquicardia Auricular / SVT	1,853	0.19 %	24,189	0.28 %
Grupo 2: Trastornos de Conducción (Bloqueos)						
440	RBBB	Bloqueo de Rama Derecha (BRD)	60,383	6.05 %	517,610	6.01 %
460	LBBB	Bloqueo de Rama Izquierda (BRI)	24,125	2.42 %	265,644	3.09 %
101	1AVB	Bloqueo AV de 1er Grado	70,022	7.02 %	363,766	4.23 %
106	CHB	Bloqueo AV Completo (3er Grado)	624	0.06 %	3,972	0.05 %
Grupo 3: Latidos Prematuros (Extrasístoles)						
231	PVC	Extrasístoles Ventriculares	51,242	5.13 %	451,720	5.25 %
222	PAC	Extrasístoles Auriculares	36,636	3.67 %	315,116	3.66 %

Cuadro 2: Prevalencia clínica de 12 alteraciones frecuentes agrupadas por categoría funcional.

Observaciones principales sobre la distribución diagnóstica:

- **Notable coherencia interhospitalaria**: A pesar de corresponder a poblaciones y períodos temporales distintos, las proporciones relativas de cada condición son extraordinariamente similares entre Emory y MGH. Por ejemplo, el bloqueo de rama derecha se sitúa exactamente en 6.0 % en ambas instituciones, la fibrilación auricular oscila entre 7.8 % y 9.2 %, y las extrasístoles ventriculares presentan prevalencias casi idénticas (5.1 % frente a 5.2 %). Esta estabilidad demuestra una alta consistencia epidemiológica en los datos.
- **Marcado desbalance de clases**: La frecuencia de las etiquetas varía en varios órdenes de magnitud. El ritmo sinusal normal representa la mitad de los estudios (≈ 51 %), mientras que alteraciones severas como el bloqueo auriculoventricular completo apenas alcanzan el 0.05 % (4,596 casos totales en 9.6 millones de exámenes). Este desbalance natural es un factor crítico a considerar al seleccionar las métricas de evaluación del modelo.

Nota aclaratoria sobre el código de Bloqueo de Rama Izquierda (LBBB): En el artículo original de HEEDB [1] se asoció por error el código `410` (que en el catálogo oficial corresponde a bajo voltaje de la onda QRS). Para garantizar la exactitud de este estudio, aquí utilizamos el código oficial verdadero del Bloqueo de Rama Izquierda, que es el `460` (`LBBB`). Este código identifica con precisión 289,769 casos reales en la base de datos (24,125 en Emory y 265,644 en MGH).

4.3 Evidencia Empírica de Mezclas Diagnósticas (Naturaleza Multietiqueta)

Al examinar las anotaciones de los especialistas, se comprueba de inmediato que la gran mayoría de los electrocardiogramas no contienen un solo diagnóstico aislado, sino combinaciones de varios hallazgos presentes al mismo tiempo.

4.3.1 Cantidad de Códigos Asignados por Trazado

El Cuadro 3 desglosa el número de códigos de diagnóstico asignados a cada estudio en el campo `codes_physician`:

Complejidad del Trazado (Nº Códigos)	**Emory (998,168)**		**MGH (8,608,018)**	
	Registros	**%**	**Registros**	**%**
1 código (Diagnóstico único aislado)	13,682	1.37 %	98,081	1.14 %
2 códigos	43,685	4.38 %	242,448	2.82 %
3 códigos	159,321	15.96 %	555,183	6.45 %
4 códigos	185,633	18.60 %	528,948	6.14 %
5 códigos	147,052	14.73 %	950,318	11.04 %
Más de 5 códigos (Diagnóstico compuesto)	448,795	44.96 %	6,233,040	72.41 %
Total con ≥ 2 códigos (Multietiqueta)	**984,486**	**98.63 %**	**8,509,937**	**98.86 %**

Cuadro 3: Distribución de la cantidad de códigos de diagnóstico por trazado.

Hallazgo principal: En ambos hospitales, **más del 98.6 % de los trazados reciben dos o más etiquetas simultáneas**, mientras que apenas el 1.2 % presenta un único código. En MGH, de hecho, más del 72 % de los estudios acumula más de cinco etiquetas. Esta evidencia descarta que el diagnóstico de un ECG pueda formularse como una elección exclusiva.

4.3.2 Combinaciones Diagnósticas más Frecuentes

Para ilustrar cómo conviven estas alteraciones en los pacientes reales, se cuantificaron las asociaciones concurrentes más comunes:

A. Ritmo de Base junto con Bloqueos de Conducción: Describe a pacientes en quienes coexisten el ritmo principal del corazón (como ritmo sinusal o fibrilación auricular) y un trastorno en la conducción ventricular (bloqueo de rama derecha o izquierda). Como indica el Cuadro 4, esta concurrencia ocurre en cientos de miles de trazados, demostrando la simultaneidad de ambos procesos.

Ritmo Base	**Bloqueo**	**Descripción Clínica**	**Emory**		**MGH**	
			Casos	**%**	**Casos**	**%**
`NSR` (22)	`RBBB` (440)	Sinusal con Bloqueo de Rama Derecha	23,358	2.34 %	217,921	2.53 %
`NSR` (22)	`LBBB` (460)	Sinusal con Bloqueo de Rama Izquierda	9,334	0.94 %	117,283	1.36 %
`NSR` (22)	`1AVB` (101)	Sinusal con Bloqueo AV de 1er Grado	1,692	0.17 %	70,259	0.82 %
`AFIB` (161)	`RBBB` (440)	Fibrilación Auricular con Bloqueo Rama Der.	7,392	0.74 %	81,873	0.95 %

Cuadro 4: Concurrencia entre ritmo de base y bloqueos de conducción.

B. Ritmo de Base junto con Latidos Prematuros (Extrasístoles): Se produce cuando, sobre el ritmo cardíaco principal, irrumpen latidos aislados que se anticipan al ciclo regular. El Cuadro 5 confirma que las extrasístoles ventriculares y auriculares conviven con regularidad tanto en pacientes con ritmo sinusal como en aquellos con fibrilación auricular.

Ritmo Base	Ectopia	Descripción Clínica	Emory		MGH	
			Casos	%	Casos	%
NSR (22)	PVC (231)	Sinusal con Extrasístoles Ventriculares	3,823	0.38 %	128,714	1.50 %
NSR (22)	PAC (222)	Sinusal con Extrasístoles Auriculares	2,264	0.23 %	82,157	0.95 %
AFIB (161)	PVC (231)	Fibrilación Auricular con Extrasístoles Vent.	1,498	0.15 %	29,908	0.35 %

Cuadro 5: Concurrencia entre ritmo de base y latidos anticipados (extrasístoles).

C. Coexistencia de Dos Alteraciones Simultáneas: Corresponde a la presencia combinada de dos anomalías estructurales o de conducción en un mismo paciente. Como detalla el Cuadro 6, es frecuente observar un bloqueo auriculoventricular de primer grado junto a un bloqueo de rama derecha, o la presencia paralela de extrasístoles auriculares y ventriculares.

Condición 1	Condición 2	Descripción Clínica	Emory		MGH	
			Casos	%	Casos	%
1AVB (101)	RBBB (440)	Bloqueo AV 1er Grado con Bloqueo Rama Der.	8,032	0.80 %	44,808	0.52 %
PAC (222)	PVC (231)	Doble Ectopia Simultánea (Auricular y Vent.)	3,930	0.39 %	38,926	0.45 %

Cuadro 6: Coexistencia de dos alteraciones adicionales en el mismo estudio.

4.4 Justificación Práctica del Enfoque Multietiqueta

Las asociaciones clínicas documentadas en las tablas anteriores demuestran por qué los diagnósticos de un electrocardiograma no pueden tratarse como opciones mutuamente excluyentes:

- **Carácter multidimensional**: Un trazado evalúa simultáneamente el marcapasos principal (ritmo), la integridad de las vías de conducción (bloqueos) y la irritabilidad ventricular o auricular (extrasístoles). Cada componente describe una faceta fisiológica distinta.
- **No exclusión mutua**: Diagnosticar un bloqueo de conducción no descarta la presencia de ritmo sinusal, ni padecer fibrilación auricular impide presentar latidos ectópicos prematuros.

Si este problema se formulara como una clasificación tradicional de clase única (*multiclase*), el modelo se vería forzado a elegir un único diagnóstico por estudio y descartar arbitrariamente las demás condiciones presentes en la señal. En cambio, una arquitectura **multietiqueta** (*multi-label*) permite predecir la presencia o ausencia de cada patología de forma independiente, ajustándose con total naturalidad a la realidad clínica [2, 1].

5. Consideraciones de Normalización, Viabilidad y Procesamiento

Se analizan tres aspectos técnicos y metodológicos indispensables antes de abordar el modelado automático:

5.1 Normalización Técnica: Frecuencias de Muestreo y Remuestreo Antialiasing

Ambas instituciones proporcionan electrocardiogramas de 12 derivaciones con duración de 10 segundos y calibración de 1,000 ADC/mV. Sin embargo, presentan disparidades técnicas que exigen estandarización previa:

- **Formatos binarios dispares**: MGH utiliza MATLAB (`.mat`) y Emory binarios planos (`.dat`), ambos con encabezados ASCII (`.hea`) leídos directamente mediante `wfdb-python`.
- **¿Por qué los modelos exigen la misma dimensión?**: Una red neuronal o clasificador computacional posee una capa de entrada fija con un número invariable de conexiones o pesos matemáticos (análogo a una tabla de base de datos con columnas fijas). No puede procesar datos de longitud variable en un mismo lote. Como resume el Cuadro 7, a 500 Hz un trazo entrega matrices de $12 \times 5{,}000$ puntos (60,000 números) y a 250 Hz entrega $12 \times 2{,}500$ (30,000 números). Mezclarlos sin homologación genera un error insalvable de dimensiones (*shape mismatch*).
- **Teorema de Nyquist y Filtro Antialiasing**: Nyquist establece que para capturar fielmente una onda sin perder información basta con medir al menos al doble de su frecuencia máxima ($f_s \geq 2 \cdot f_{\text{máx}}$). Como el ancho de banda clínico del ECG llega hasta los 125 Hz, una tasa de 250 Hz cumple con exactitud este criterio ($2 \times 125 = 250$ Hz), reteniendo todo el valor diagnóstico. Al reducir de 500 a 250 Hz no se puede simplemente borrar una de cada dos muestras; de hacerlo, los ruidos rápidos se "disfrazarían" como ondas lentas artificiales (*aliasing*, similar al efecto óptico en que las ruedas de un auto parecen girar al revés en video), inventando arritmias falsas. El **filtro antialiasing** limpia previamente todo ruido superior a 125 Hz antes de reducir puntos, preservando la forma real intacta.

Tasa Original	Puntos / Derivación	% MGH	% Emory	Problema de Tamaño y Solución Técnica
500 Hz	5,000 muestras	53 %	78 %	Matriz grande ($12 \times 5{,}000$). No cabe en entradas para 2,500 puntos.
250 Hz	2,500 muestras	47 %	22 %	Matriz base ($12 \times 2{,}500$). Resolución clínica estándar y óptima.
Remuestreo 500→250	2,500 muestras	100 %	100 %	El filtro antialiasing limpia el ruido rápido antes de reducir puntos, igualando todas las matrices a $12 \times 2{,}500$ sin deformar la onda.

Cuadro 7: Homologación de tamaños de señal y justificación práctica del filtro antialiasing.

5.2 Compatibilidad de Criterios de Anotación Médica

Aunque ambos centros comparten el algoritmo GE Marquette 12SL y el catálogo maestro de 505 términos (`diagnoses_dictionary.csv`), compartir el vocabulario no asegura criterios idénticos:

- **Diferencias de sobrelectura**: En Emory la validación por cardiólogo cubrió el 99.93 %, mientras que en MGH la supervisión médica documentada alcanza el 81.14 %.
- **Origen del diagnóstico**: En MGH, parte de las etiquetas se extrajo de notas libres mediante procesamiento de lenguaje natural y concordancia de cadenas, introduciendo variabilidad inexistente en la codificación directa de Emory.
- **Prudencia metodológica**: Conviene verificar la consistencia clínica mediante pruebas cruzadas entre hospitales antes de asumir una equivalencia diagnóstica total sin sesgos institucionales.

5.3 Evaluación de Viabilidad Computacional y Requerimientos de Memoria

Cargar los registros validados en memoria RAM enfrenta una barrera física: cada examen ocupa ≈ 120 KB (10 s×12 der×500 Hz×2 B). Como resume el Cuadro 8, cargar los 9.6 millones de trazados a la vez exigiría más de **1.15 Terabytes de RAM**, colapsando cualquier equipo convencional (16 a 64 GB de RAM).

Escenario	Trazados	RAM Estimada	Factibilidad y Solución Técnica
HEEDB Completo	11,607,259	≈ 1.39 TB	Inviable en RAM local; requiere almacenamiento distribuido.
Universo Validado	9,606,186	≈ 1.15 TB	Inviable en RAM física; exige lectura por demanda (*lazy loading*).
Piloto Experimental	100,000	≈ 12 GB	**Totalmente viable** en estaciones estándar (16–32 GB de RAM).
Enfoque Tabular	9,606,186	≈ 480 MB	**Óptima**; almacenable en cualquier equipo personal.

Cuadro 8: Consumo estimado de memoria y viabilidad técnica según escenario.

Justificación y ruta metodológica recomendada: Ante este obstáculo de memoria, se justifica una ruta de tres fases progresivas:

1. **Fase 1: Prototipo piloto (100,000 trazos ≈ 12 GB)**: Permite programar y depurar los algoritmos en una computadora convencional (16–32 GB de RAM) sin incurrir en costos de clústeres o servidores en la nube.
2. **Fase 2: Modelado tabular ligero (480 MB)**: En vez de procesar ondas continuas pesadas, se entrenan modelos rápidos sobre las medidas que el electrocardiógrafo ya calculó (como la frecuencia cardíaca y duración de ondas en `metadata.csv`). Ocupa solo 480 MB y da una línea base diagnóstica inmediata.
3. **Fase 3: Escalado masivo con lectura por demanda**: Con el flujo de trabajo ya validado, se escala al total de señales leyendo lotes pequeños del disco a la GPU (*lazy loading*), evitando saturar la memoria RAM.

5.4 Pautas Estructurales para la Limpieza de Datos

Para la preparación rigurosa de los registros se deben contemplar cuatro pautas técnicas:

- **Agrupación estricta por paciente**: Debido a que cada paciente acumula múltiples estudios, la partición (entrenamiento, validación y prueba) debe agruparse obligatoriamente por `BDSPPatientID` para evitar fuga de información (*data leakage*).
- **Saneamiento de rutas en MGH**: En `diagnoses_v24.csv` de MGH, la columna `FileName` incluye prefijos (`./`) y sufijos (`.hea`, `\n`) que deben removerse antes de los cruces con `metadata.csv`.
- **Homologación del identificador**: En Emory, `BDSPPatientID` suele leerse como decimal (`179020000.0`) en Pandas; debe convertirse a texto o entero para mantener coherencia con MGH.
- **Filtrado por códigos técnicos**: El sistema 12SL asigna códigos específicos para artefactos (como `1672` inversión de electrodos o `1673` baja calidad), útiles para filtrar trazos corruptos antes del entrenamiento [1].

5.5 Síntesis del Análisis Exploratorio y Próximos Pasos

La exploración de HEEDB confirma un repositorio de enorme valor clínico. Las tres conclusiones directas son:

- Las prevalencias de las 12 alteraciones son muy consistentes entre Emory y MGH.
- El 98.6 % de diagnósticos compuestos hace indispensable una formulación multietiqueta.
- El remuestreo antialiasing a 250 Hz y el piloto de 100,000 trazos garantizan la viabilidad técnica y computacional del proyecto previo al escalado masivo.

6. Diccionario de Conceptos Clave (Glosario Técnico y Clínico)

Para facilitar la comprensión del documento a evaluadores y estudiantes de Ingeniería de Sistemas, a continuación se definen los términos fundamentales organizados en tres dominios:

6.1 Dominio Electrofisiológico y Señales Biomédicas

- **ECG de 12 Derivaciones**: Prueba electrofisiológica que registra la actividad bioeléctrica cardíaca desde 12 perspectivas espaciales simultáneas (6 frontales y 6 precordiales).
- **Frecuencia de Muestreo (f_s)**: Número de medidas capturadas por segundo (en Hertz, Hz). En HEEDB coexisten registros a 250 Hz (2,500 datos en 10 s) y 500 Hz (5,000 datos en 10 s).
- **Teorema de Nyquist**: Principio que establece que para registrar una onda continua sin perder información se debe muestrear al menos al doble de su frecuencia máxima ($f_s \geq 2 \cdot f_{\text{máx}}$). En ECG (125 Hz), 250 Hz es la tasa óptima exacta.
- **Incompatibilidad de Tamaño (*Shape Mismatch*)**: Error en algoritmos cuando los datos de entrada difieren en longitud; los modelos exigen matrices de tamaño fijo.
- **Remuestreo Digital**: Proceso para igualar la cantidad de puntos de todos los exámenes (reduciendo 500 Hz a 250 Hz) para obtener dimensiones homogéneas.
- **Efecto Aliasing (Distorsión por Submuestreo)**: Fenómeno donde ruidos rápidos se confunden y generan ondas falsas lentas al reducir puntos (similar a las ruedas que parecen girar al revés en video).
- **Filtro Antialiasing (Limpiador Previo)**: Algoritmo digital que suaviza y elimina ruidos rápidos antes de descartar muestras, asegurando que la onda cardíaca conserve su forma real.
- **Complejo QRS e Intervalos (PR, QT)**: Componentes de cada latido: el **QRS** es el pico alto y puntiagudo que bombea la sangre al cuerpo, mientras que los **intervalos PR y QT** miden en milisegundos los tiempos de viaje eléctrico y recarga del corazón.

6.2 Dominio de Aprendizaje Automático e Inteligencia Artificial

- **Homogeneidad Dimensional**: Requisito donde todas las matrices de entrada deben compartir la misma forma fija ($12 \times 2{,}500$), ya que las capas del modelo poseen un número rígido de conexiones matemáticas.
- **Clasificación Multietiqueta (*Multi-label*)**: Paradigma donde una instancia (un ECG) puede pertenecer simultáneamente a varias clases no excluyentes (ej. ritmo sinusal y bloqueo de rama).
- **Clasificación Multiclase (*Multi-class*)**: Paradigma tradicional donde cada instancia solo puede pertenecer a una única clase excluyente (inadecuado para diagnósticos cardíacos compuestos).
- **Desbalance de Clases**: Distribución asimétrica donde algunas clases son muy abundantes (ritmo sinusal $\sim 51\,\%$) y otras sumamente escasas (bloqueo AV completo al $0.05\,\%$).
- **Fuga de Datos (*Data Leakage*)**: Contaminación involuntaria del conjunto de prueba con información de entrenamiento (por ejemplo, al no agrupar los estudios de un mismo paciente).
- **Sobrelectura Médica (*Physician Over-reading*)**: Proceso de revisión donde un cardiólogo o especialista humano audita, corrige y valida el informe emitido por el electrocardiógrafo.

6.3 Dominio de Arquitectura e Ingeniería de Datos

- **Formato WFDB (*WaveForm DataBase*)**: Estándar biomédico de PhysioNet compuesto por un encabezado de texto plano (`.hea`) y una matriz binaria de señal (`.mat` o `.dat`).
- **Algoritmo GE Marquette 12SL**: Software hospitalario integrado en electrocardiógrafos para medir intervalos y sugerir diagnósticos automáticos a partir del trazado.
- **Ontología Diagnóstica**: Catálogo estructurado de 505 términos numéricos estandarizados utilizado para traducir los códigos numéricos a diagnósticos clínicos comprensibles.
- **Carga Bajo Demanda (*Lazy Loading*)**: Estrategia que lee archivos del disco solo al ingresar el lote a la GPU, evitando saturar la memoria RAM.

7. Referencias Bibliográficas

[1] Z. Koscova, Q. Li, C. Robichaux, V. Moura Junior, M. Ghanta, A. Gupta, J. Rosand, A. D. Aguirre, E. Reinertsen, S. Song, S. Hong, D. E. Albert, J. Xue, A. Parekh, R. Sameni, M. A. Reyna, M. B. Westover y G. D. Clifford, "The Harvard-Emory ECG Database," *Scientific Data*, vol. 13, no. 1, art. 516, 2026. DOI: https://doi.org/10.1038/s41597-026-06861-9

[2] E. A. P. Alday, A. Gu, A. J. Shah, C. Robichaux, A. I. Wong, C. Liu, F. Liu, A. B. Rad, A. Elola, S. Seyedi, Q. Li, R. Agrawal, M. A. Reyna y G. D. Clifford, "Classification of 12-lead ECGs: the PhysioNet/Computing in Cardiology Challenge 2020," *Physiological Measurement*, vol. 41, no. 12, art. 124003, 2020. DOI: https://doi.org/10.1088/1361-6579/abc960